

IDENTIFICAÇÃO COMPUTACIONAL INTELIGENTE DE DISFUNÇÕES NO TRATO VOCAL

RONALDO CHIAVEGATTI SAMPAIO CORRÊA, RODRIGO CAPOBIANCO GUIDO, Instituto de Biociências, Letras e Ciências Exatas – IBILCE, Câmpus de São José do Rio Preto, ronaldo.correa@unesp.br

Apresentado no XXXVIII Congresso de Iniciação Científica da Unesp – CIC 2026

"Unesp 50 Anos: Ciência, Formação, Inovação e Transformação nos Territórios"

INTRODUÇÃO: O diagnóstico diferencial de distúrbios vocais costuma exigir exame endoscópico, e o caso mais difícil é separar as disfonias funcionais sem lesão estrutural — psicogênica e funcional — de quadros orgânicos como laringite e edema de Reinke. A análise acústica computacional desponta como triagem não invasiva e de baixo custo. Este trabalho avalia um classificador de cinco condições vocais a partir de vogais sustentadas, em C99 puro, sem frameworks de aprendizado de máquina. A contribuição desta etapa é metodológica: cada decisão de projeto passou por comparação A/B reproduzível — mesma semente, mesmas dobras — com adoção ou rejeição por regra fixa definida antes de ver o resultado.

MATERIAL E MÉTODOS: Usou-se um subconjunto de 1.098 pacientes da Saarbrücken Voice Database (BARRY; PÜTZER, 2007), nas cinco classes e nos tamanhos da Tabela 1, com as vogais sustentadas /a/, /i/ e /u/. (i) Extração: 83 características por vogal — 10 temporais (jitter, shimmer, HNR, ZCR), 55 espectrais (F0, formantes F1–F4, entropia, centroide, rolloff, 13 MFCC com Δ e $\Delta\Delta$, CPP, pulso glotal) e 18 wavelet (Daubechies-4, seis níveis; GUIDO, 2022) — que, com idade e sexo, somam 251 variáveis. (ii) Protocolo: cinco dobras estratificadas, semente fixa (42); z-score ajustado só nas amostras originais de treino; augmentação e balanceamento apenas no treino de cada dobra. (iii) Arquitetura: fusão tardia multi-vogal — por vogal, uma rede binária ("Mestra", patológico $\times$ saudável) e uma de quatro classes ("Especialista"), ambas com camadas ocultas [128, 64], LeakyReLU, dropout, L2, Adam (KINGMA; BA, 2015) e parada por Macro F1; as três vogais entram por média das probabilidades, com limiar $P(\text{patológico}) \geq 0,5$. (iv) Experimentos A/B: SMOTE padrão $\times$ Borderline-SMOTE1 (HAN; WANG; MAO, 2005), doze combinações de arquitetura e regularização, e a seleção paraconsistente de características; McNemar para significância e bootstrap ($N = 1000$) para os intervalos.

RESULTADOS E DISCUSSÃO: A configuração adotada alcançou acurácia de 69,7% [IC 95%: 66,9–72,3%] e Macro F1 de 0,4587 [0,419–0,495] (Tabela 1), superando os três baselines — classe majoritária, k-NN e regressão logística — por McNemar ($p < 0,001$ em todos). Experimentos A/B: o Borderline-SMOTE1 foi adotado por elevar o Macro F1 em 0,0228, com ganho concentrado nas duas classes menores, embora a diferença entre os braços não seja significativa ($p = 0,6606$); das doze combinações, [128, 64] foi mantida por ser a mais parcimoniosa dentro de um erro-padrão da melhor e não inferior a ela ($p = 0,7463$); e a seleção paraconsistente foi rejeitada, por não descartar nenhuma característica (0% de redução) e reduzir o Macro F1 em 0,0032 — resultado negativo reportado por transparência, não uma técnica do modelo final. Erros: Normal foi a classe mais bem discriminada ($F1 = 0,867$, recall de

92%), seguida do Edema de Reinke ($F1 = 0,456$), única com lesão estrutural. A Figura 1 mostra 37 dos 203 pacientes das duas disfonias funcionais trocados entre si — coerente com a literatura sobre sobreposição acústica entre disfonias sem lesão estrutural (LEE, 2021; VRBA et al., 2025).

	Normal (687)	Laring. (140)	D. Psic. (91)	D. Func. (112)	Reinke (68)
Normal (687)	632	17	12	13	13
Laring. (140)	54	45	7	6	28
D. Psic. (91)	33	7	29	10	12
D. Func. (112)	43	11	27	20	11
Reinke (68)	9	6	10	4	39
	Normal	Laring.	D. Psic.	D. Func.	Reinke
	Classe prevista pelo modelo				

Figura 1. Matriz de confusão agregada (1.098 pacientes, cinco dobras). Diagonal = acertos.

Tabela 1. Desempenho por classe (predições fora da dobra de treino).

Classe	Precisão	Recall	F1-Score	n
Normal	0,820	0,920	0,867	687
Laringite	0,523	0,321	0,398	140
Disfonia Psicogênica	0,341	0,319	0,330	91
Disfonia Funcional	0,377	0,179	0,242	112
Edema de Reinke	0,379	0,574	0,456	68

CONCLUSÕES: A triagem entre voz saudável e patológica mostrou-se viável (Normal: $F1 = 0,867$, recall de 92%) e o Edema de Reinke foi separado com $F1$ de 0,456. O diferencial entre as duas disfonias funcionais segue como gargalo: $F1$ de 0,330 e 0,242, sem que nenhum dos 12 braços superasse 0,36 e 0,27 nessas classes — evidência de um teto do próprio sinal acústico, que deve exigir informação além da voz. Das três técnicas previstas na proposta original, duas se confirmaram e uma foi descartada pela evidência A/B.

AGRADECIMENTOS: Ao Prof. Dr. Eng. Rodrigo Capobianco Guido, pela orientação; ao IBILCE/Unesp, pela infraestrutura; e aos autores da Saarbrücken Voice Database. IC voluntária, sem bolsa.

REFERÊNCIAS

- BARRY, W. J.; PÜTZER, M. Saarbrücken Voice Database. Universität des Saarlandes, 2007. Acesso em: 26 jul. 2026.
- HAN, H.; WANG, W.-Y.; MAO, B.-H. Borderline-SMOTE: a new over-sampling method in imbalanced data sets learning. LNCS, v. 3644, p. 878-887, 2005.
- GUIDO, R. C. Wavelets behind the scenes: practical aspects, insights, and perspectives. Physics Reports, v. 985, 2022.
- KINGMA, D. P.; BA, J. Adam: a method for stochastic optimization. ICLR, 2015.
- LEE, J.-Y. Experimental evaluation of deep learning methods for an intelligent pathological voice detection system using the Saarbruecken Voice Database. Applied Sciences, v. 11, n. 15, art. 7149, 2021.
- VRBA, J. et al. Reproducible machine learning-based voice pathology detection: introducing the pitch difference feature. Journal of Voice, 2025.